



Facultad de Ingeniería

Procesamiento de Lenguaje Natural

Trabajo practico grupal integrador: Clasificación y Recomendación de artículos científicos

Año 2026 - 1° cuatrimestre

Profesores:

- VICTOR EZEQUIEL MUÑOZ
- NICOLAS RUBINSTEIN

Integrantes:

- | | | |
|--------------------------------|---------|---------|
| • ANDRES CHOLAKIAN | Legajo: | 0150469 |
| • GONZALO DANIEL GRECCO | Legajo: | 0145636 |
| • NICOLAS MILLE | Legajo: | |
| • SIMÓN MARTÍN RUBIÑO MONTILLA | Legajo: | 0134610 |

Contenido

Resumen	3
1. Introducción.....	3
1.1 Problema y Motivación.....	3
1.2 Enfoque Asumido	4
1.3 Objetivos.....	4
2. Trabajos Relacionados.....	5
3. Metodología.....	6
3.1 Descripción del Dataset	6
3.2 Definición de Labels (Macro-categorías)	6
3.3 Balanceo de Clases	7
3.4 Preprocesamiento de Texto	7
3.5 Clasificación con TF-IDF.....	7
3.6 Embeddings con SciBERT.....	8
3.7 Sistema de Recomendación	8
3.8 Evaluación del Sistema de Recomendación (Enfoque Multicriterio)	8
3.9 Infraestructura Computacional.....	9
4. Experimentos y Resultados.....	10
4.1 Resultados de Clasificación.....	10
4.1.1 Modelos TF-IDF	10
4.1.2 Clasificación con SciBERT	11
4.2 Resultados del Sistema de Recomendación	11
4.3 Evaluación Cualitativa por Categoría (SciBERT).....	11
4.4 Visualizaciones	12
5. Discusión, Análisis de Errores y Limitaciones	14
5.1 Análisis de Errores.....	14
5.2 Limitaciones.....	14
5.3 Lecciones Aprendidas.....	15
6. Conclusiones.....	16
6.1 Resumen de Hallazgos.....	16
6.2 Contribuciones.....	16

Resumen

El crecimiento exponencial de la producción científica dificulta la identificación de artículos relevantes para investigadores y estudiantes. Este trabajo aborda dos problemas complementarios en el dominio de artículos científicos de arXiv: la clasificación temática de documentos y la recomendación de artículos semánticamente similares. Se implementaron y compararon dos enfoques: un pipeline clásico basado en TF-IDF con modelos de clasificación (Regresión Logística, Naive Bayes y SVM) y un enfoque avanzado utilizando embeddings contextuales del modelo SciBERT. Los resultados muestran que TF-IDF + SVM alcanza una precisión del 85.7% en clasificación, mientras que SciBERT logra una precisión del 83.4% en la tarea de recomendación (Precision@5), demostrando que la elección del método óptimo depende de la tarea específica.

1. Introducción

1.1 Problema y Motivación

El volumen de artículos científicos publicados crece a un ritmo sin precedentes. Plataformas como arXiv albergan millones de preprints, lo que hace cada vez más difícil para los investigadores mantenerse al día con la literatura relevante en sus áreas. Esta sobrecarga de información motiva el desarrollo de sistemas automatizados que puedan:

1. Clasificar automáticamente nuevos artículos en categorías temáticas, facilitando su organización y búsqueda.
2. Recomendar artículos relacionados a partir de un documento de interés, ayudando a los usuarios a descubrir trabajos relevantes que de otra forma pasarían desapercibidos.

1.2 Enfoque Asumido

El presente trabajo aborda estos problemas desde dos perspectivas complementarias:

- Clasificación supervisada: Se entrena un modelo para predecir la macro-categoría temática de un artículo a partir de su título y resumen (abstract).
- Sistema de recomendación: Se implementa un sistema basado en similitud del coseno entre representaciones vectoriales de los documentos, permitiendo sugerir artículos semánticamente afines.

Ambos enfoques se implementan utilizando técnicas de vectorización de texto clásicas (TF-IDF) y modernas (embeddings contextuales con SciBERT), con el objetivo de comparar su desempeño en cada tarea.

1.3 Objetivos

- Implementar un pipeline completo de Procesamiento de Lenguaje Natural (PLN) que incluya preprocesamiento, vectorización, clasificación y recomendación.
- Comparar el desempeño de TF-IDF versus SciBERT en tareas de clasificación y recomendación.
- Evaluar los sistemas utilizando métricas estándar (accuracy, F1-score, Precision@k) y un enfoque de relevancia multicriterio sugerido por el docente.

2. Trabajos Relacionados

El problema de clasificación y recomendación de documentos académicos ha sido ampliamente estudiado en la literatura.

Clasificación de textos científicos: Trabajos clásicos como los de Sebastiani (2002) establecieron las bases para la clasificación automática de textos utilizando representaciones basadas en frecuencia de términos (Bag of Words, TF-IDF) y modelos como Naive Bayes y SVM. Más recientemente, Li et al. (2022) presentan una revisión exhaustiva de la evolución desde enfoques tradicionales hasta métodos basados en deep learning.

Embeddings científicos: Beltagy et al. (2019) introdujeron SciBERT, un modelo BERT pre-entrenado sobre 1.14 millones de artículos científicos de múltiples disciplinas, demostrando mejoras significativas en tareas de PLN en el dominio científico. Cohan et al. (2020) propusieron SPECTER, un modelo específicamente diseñado para generar embeddings de documentos científicos utilizando pares de papers que se citan mutuamente.

Sistemas de recomendación: La evaluación de sistemas de recomendación ha sido estandarizada con métricas como Precision@k, Recall@k y NDCG (Järvelin & Kekäläinen, 2002). Sin embargo, como señala el docente, la definición de "relevancia" en el contexto de artículos científicos es compleja y multicriterio.

3. Metodología

3.1 Descripción del Dataset

Se utilizó el arXiv Dataset disponible en Kaggle (Cornell University), que contiene metadatos de aproximadamente 2 millones de artículos científicos. Para este trabajo, se extrajeron los siguientes campos:

Campo	Descripción
id	Identificador único del artículo
Title	Título del artículo
Abstract	Resumen del artículo
categories	Categorías temáticas (ej. cs.CL, cs.LG, stat.ML)

Preprocesamiento inicial:

- Se combinó title y abstract en un único campo text.
- Se aplicó limpieza de texto: conversión a minúsculas, eliminación de caracteres especiales y espacios múltiples.
- Se trabajó con una muestra estratificada de **150,000 artículos** para el desarrollo inicial.
- Tras el filtrado de categorías y balanceo, se utilizaron **5,248 artículos** para el entrenamiento final, distribuidos equitativamente entre 7 macro-categorías.

3.2 Definición de Labels (Macro-categorías)

Siguiendo la recomendación del docente, se utilizó la taxonomía de arXiv para mapear las subcategorías a macro-categorías:

Prefijo	Macro-categoría
cs	Computer Science
Math	Mathematics
Stat	Statistics
Physics	Physics
Astro-ph	Astrophysics
q-bio	Quantitative Biology
q-fin	Quantitative Finance

Se implementó una función **get_primary_category()** que extrae la primera categoría de la lista como categoría primaria (single-label classification).

3.3 Balanceo de Clases

Debido al desbalance natural de las categorías, se aplicó una técnica de submuestreo utilizando `sklearn.utils.resample`, tomando 750 muestras por categoría (748 para Quantitative Finance debido a su menor disponibilidad). Esto garantizó una distribución equitativa y evitó sesgos hacia categorías mayoritarias.

3.4 Preprocesamiento de Texto

El preprocesamiento se realizó exclusivamente en CPU, utilizando:

- Normalización: Conversión a minúsculas.
- Limpieza: Eliminación de caracteres especiales utilizando expresiones regulares.
- Tokenización y lematización: Implementadas como opcionales (se dejaron comentadas para preservar la riqueza léxica para los modelos).

3.5 Clasificación con TF-IDF

Se implementó un pipeline clásico para la clasificación de artículos:

1. Vectorización: TF-IDF con `max_features=10,000` y n-grams de rango (1,2) (unigramas y bigramas).
2. Modelos evaluados:
 - a. Regresión Logística (`max_iter=1000`)
 - b. Naive Bayes (MultinomialNB)
 - c. Linear SVM (`max_iter=2000`)
3. Validación: Split train/test 80/20 con estratificación por categoría.

3.6 Embeddings con SciBERT

Se utilizó el modelo pre-entrenado `allenai/scibert_scivocab_uncased` de Hugging Face para generar embeddings contextuales:

1. Configuración: Modelo ejecutado en GPU (Tesla T4 en Google Colab) para aceleración computacional.
2. Generación: Procesamiento por batches (`batch_size=8`) con truncamiento a 512 tokens.
3. Embedding del documento: Uso del token [CLS] como representación de cada artículo.
4. Clasificación: Regresión Logística sobre los embeddings generados.

3.7 Sistema de Recomendación

Se implementaron dos sistemas de recomendación basados en **similitud del coseno**:

- Recomendador TF-IDF: Utiliza la misma representación TF-IDF generada para clasificación.
- Recomendador SciBERT: Utiliza los embeddings generados por SciBERT.

Funcionamiento: Para un artículo de consulta, se calcula la similitud del coseno contra todos los demás documentos y se retornan los k más similares.

3.8 Evaluación del Sistema de Recomendación (Enfoque Multicriterio)

Siguiendo las sugerencias del profesor, se implementó un sistema de relevancia multicriterio que considera:

Criterio	Peso	Descripción
Misma categoría principal	1.0	Coincidencia exacta del prefijo (ej. cs → cs)
Misma macro-categoría	0.5	Coincidencia a nivel de macro-categoría
Coautoría	0.3	Superposición de autores (cuando el campo está disponible)
Superposición de vocabulario	0.2	Jaccard sobre palabras clave (simplificado)

Métricas calculadas:

- Precision@5: Proporción de recomendaciones relevantes entre las 5 primeras.
- Recall@5: Proporción de ítems relevantes totales que aparecen en el top-5.

3.9 Infraestructura Computacional

Componente	Especificación
Desarrollo	Google Colab (GPU Tesla T4, 15.6 GB VRAM)
CPU	Intel Xeon (1 núcleo, 13.6 GB RAM)
Librerías principales	Python 3.12, PyTorch 2.11, Transformers 5.0, Scikit-learn 1.6, Pandas 2.2

4. Experimentos y Resultados


4.1 Resultados de Clasificación

4.1.1 Modelos TF-IDF

Modelo	Accuracy
Logistic Regression	0.8486
Naive Bayes	0.8505
Linear SVM	0.8571

Mejor modelo: Linear SVM con accuracy de 85.71%.

Matriz de Confusión (Linear SVM):



La matriz de confusión muestra que las confusiones más frecuentes ocurren entre categorías relacionadas (ej. Physics con Mathematics, Astrophysics con Physics), lo cual es esperable dada la naturaleza interdisciplinaria de la investigación científica.

4.1.2 Clasificación con SciBERT

Modelo	Accuracy
SciBERT + Logistic Regression	0.8429
SciBERT + Linear SVM (temporal)	0.7981

Observación: SciBERT con Logistic Regression logró un accuracy del 84.29%, ligeramente inferior al mejor modelo con TF-IDF (85.71%). Esto sugiere que para la clasificación de categorías generales, las representaciones basadas en frecuencia de términos son altamente efectivas y computacionalmente más eficientes.

4.2 Resultados del Sistema de Recomendación

Sistema	Precision@5	Recall@5
TF-IDF	0.7360	0.7360
SciBERT	0.8340	0.8340

Análisis: SciBERT supera claramente a TF-IDF en la tarea de recomendación (83.4% vs 73.6% de precisión). Esto se debe a que los embeddings contextuales capturan relaciones semánticas más profundas entre documentos, más allá de la simple coincidencia de términos.


4.3 Evaluación Cualitativa por Categoría (SciBERT)

Categoría	Mismas (exactas)	Recall@5
Mathematics	3/5	60%
Physics	5/5	100%
Astrophysics	5/5	100%
Computer Science	5/5	100%
Quantitative Biology	1/5	20%
Quantitative Finance	5/5	100%
Statistics	2/5	40%


Interpretación: El rendimiento es excelente para categorías bien definidas (Physics, Astrophysics, Computer Science). Las categorías más heterogéneas o con menor representación en el dataset (Quantitative Biology, Statistics) presentan mayores desafíos.

4.4 Visualizaciones

1. Mapa de calor de similitud entre macro-categorías (SciBERT): Muestra las relaciones semánticas entre categorías; Physics y Astrophysics aparecen altamente correlacionadas, lo cual es consistente con la realidad científica.



2. Visualización t-SNE de embeddings SciBERT: Los documentos se agrupan por categoría, demostrando que SciBERT aprende representaciones que discriminan efectivamente las diferentes áreas temáticas.



5. Discusión, Análisis de Errores y Limitaciones

5.1 Análisis de Errores

Errores en clasificación:

- Confusiones entre Physics y Mathematics: Artículos en la intersección de ambas disciplinas (ej. física matemática) son inherentemente difíciles de clasificar.
- Bajo rendimiento en Quantitative Biology (20% de precisión en recomendación): Esta categoría es altamente interdisciplinaria y el modelo puede no haber capturado sus características distintivas con suficientes ejemplos.

Errores en recomendación:

- En TF-IDF, las recomendaciones tienden a favorecer coincidencias léxicas superficiales, lo que explica su menor precisión comparado con SciBERT.

5.2 Limitaciones

Limitación	Descripción	Impacto
Tamaño de la muestra	Se trabajó con una submuestra de 150k artículos (de ~2M disponibles)	Limitada generalización
Hardware	Entrenamiento limitado por recursos de GPU	Imposibilidad de fine-tuning de SciBERT
Evaluación de relevancia	Definición de relevancia basada únicamente en categorías y autores	Posible subestimación de recomendaciones válidas
Preprocesamiento simplificado	No se aplicó lematización ni eliminación agresiva de stopwords	Ruido en representaciones TF-IDF
Single-label classification	Se asumió una única categoría por artículo	Artículos multidisciplinares pierden información

5.3 Lecciones Aprendidas

- El mejor método depende de la tarea: TF-IDF superó a SciBERT en clasificación (85.7% vs 84.3%), mientras que SciBERT fue superior en recomendación (83.4% vs 73.6%).
- El uso de GPU es crucial para modelos de transformadores; sin ella, la generación de embeddings para 5,000 documentos habría tomado horas en lugar de minutos.
- El balanceo de clases fue fundamental para evitar sesgos hacia categorías mayoritarias como Mathematics y Astrophysics.

6. Conclusiones

6.1 Resumen de Hallazgos

Este trabajo implementó y comparó dos enfoques para la clasificación y recomendación de artículos científicos del arXiv:

1. Clasificación: El mejor modelo fue Linear SVM con TF-IDF (85.71% de accuracy). SciBERT logró un 84.29% con Regresión Logística.
2. Recomendación: SciBERT superó a TF-IDF con una Precision@5 de 83.40%, demostrando la ventaja de los embeddings contextuales para capturar similitud semántica.
3. Dependencia de la tarea: No existe un método universalmente superior; la elección debe basarse en los requisitos específicos de cada aplicación.

6.2 Contribuciones

- Implementación completa de un pipeline de PLN que abarca desde preprocesamiento hasta evaluación multicriterio.
- Comparativa sistemática entre enfoques clásicos y basados en transformers.
- Sistema de recomendación con evaluación multicriterio que considera categorías, autores y vocabulario.
- Visualizaciones interpretables (t-SNE, mapas de calor) que demuestran la calidad de los embeddings.